

开题答辩·逐页口播提示卡

开题答辩·逐页口播提示卡

《基于大模型编码智能体的自进化 eBPF 网络入侵防御系统》·李兆曦·指导教师徐恪教授总时长约 13-15 分钟。下表按幻灯片顺序, 每页给关键词式提示 (瞄一眼即讲), 非逐字稿。

封面 0.5 - 各位老师好, 我是李兆曦, 指导教师徐恪教授 - 题目报一遍 → “下面从背景、问题、相关工作、内容方法、技术路线、创新点、计划成果汇报”

目录 5 - 一句带过:“汇报分八个部分”

背景：跨层歧义 → off-path 攻击 0.7 - TCP/IP 跨层交互有语义歧义 → 催生 off-path(链外) 攻击 - 攻击者: 不在路径上、不窃听, 仅凭侧信道推 **序列号** → 劫持/重置/污染 - 例:challenge-ACK(CVE-2016-5696)、IPID、PMTUD、NAT/Wi-Fi - **CCS'25:PMTUD** 打破连接隔离 → 220 秒 / 七成成功率 / 50 网络中 38 脆弱 - 落点: 攻击面植根于“设计层面歧义”, 不断再生

背景：防御反而制造攻击面 0.5 - 关键规律: 很多新攻击面由防御自己引入 - challenge-ACK 限速 → 侧信道; 端口随机化 → 被反推 - 落点: 攻防同源、动态博弈 → 防御必须持续演化

背景：现有防御三大缺陷 0.5 - 零散 (各打各的补丁)/ 滞后 (被动响应)/ 依赖人工写内核代码 - 人工: 慢、易错、知识难沉淀 - 落点: 防御的“生产方式”仍是人工、低速、难累积

背景：两项技术成熟 0.5 - eBPF: 热加载、贴近协议栈、内置 verifier 做形式化验证 - 编码智能体: Claude Code / Cursor / Codex / Devin / SWE-agent 已能自主写改调 - 落点: 二者结合 → “让智能体持续维护内核防御”可行

核心研究问题 0.5 - 能否让编码智能体自主维护内核 eBPF 防御库, 使其持续进化? - 强调: 不是一次性合成, 而是长期自主运转 + 能力单调累积

四项关键挑战 0.7 - 可靠性 (内核代码出错 → 断网/误杀, 先验证后部署) - 探索高效性 (状态空间大且有噪声, 要找真正有价值的攻击面) - 非梯度演化收敛 (单调进化、不腐化、不回退) - 评测 (量化对未知攻击的防御)

相关工作 (一): 协议攻防 + eBPF 防御 0.7 - 攻防: off-path 系列 + 检测 (SCENT/SCAD); 防御零散滞后 - eBPF 防御: Katran/Cilium/Falco/Tetragon、verifier(PREVAIL/K2)——**策略均人工写**

相关工作 (二): LLM 安全 + 方法论 0.5 - 安全: PentestGPT/Big Sleep; Kgent/KEN (最直接基线, 但一次性合成) - 方法论: 非梯度演化、FunSearch/AlphaEvolve、Darwin-Gödel Machine、探索 (ICM/RND)、QD (Novelty/MAP-Elites)

定位对比表 0.5 - 对比 Kgent (一次合成)/ Tetragon · Falco (人工)/ 小模型 (权重) - 本文: 长期自主维护、自进化、知识沉淀为**可验证代码**

核心思路: 防御演化 0.7 - 一句话: 让 agent **持续维护与演化** 一套内核防御代码; 防御沉淀为**可验证代码**, 不是模型权重 - 优势: 容量无界 / 抗遗忘 / 可解释 / 线速 / 可形式化验证

四项研究内容 0.7 - 范式形式化 + 系统框架 + **专用 harness** (把领域工具/反馈封装, 区别于直接用通用 agent) - 新颖性与覆盖度引导的攻击面探索 - 大模型进化式 eBPF 合成 + 可信加载闭环 - 多样化防御库 + 攻防协同演化评测

系统分层架构 (看图讲) 0.7 - 三层: **控制面 · 智能体** (探索/合成/反思 + harness) → **可信验证面** (编译 → verifier → 沙箱 → 回滚) → **内核数据面** (XDP tail-call 防御链 + 遥测) - 左: 攻防靶场喂**攻击样本**; 右: **防御库/知识库**沉淀与采样 - 主流向下 (候选 eBPF → 验证通过 · 热加载); 运行时**反馈回灌**控制面再迭代

技术路线: 防御演化闭环 (五阶段) (看图讲) 1 - 探索 → 合成 → 验证 (失败 → 自修正) → 部署反馈 → 档案 → 回灌 - 一句话: 每轮把新攻击面 → 一段 verifier 背书的 eBPF 防御, 沉淀入库

可信保障: 四层 + 自动回滚 0.7 - 候选 → 静态沙箱 → 模板封装 → -Werror → **内核 verifier** (都是现成基础设施) - **创新在于接入智能体闭环**: 报错驱动**自修正**、沙箱重放把关、异常即**自动回滚**

工程基线: 已有开源系统 0.5 - PacketScope / Guarder: XDP 数据面、一键编译、热加载、Agent 可编程 eBPF 原型 + 312 测试 - 落点: 底座已具备, 闭环可快速搭

创新点 (三) 0.7 - **范式**: agent 持续维护与演化内核防御代码 (防御演化) - **专用 harness**: 领域工具 + 反馈闭环, 而非直接用通用 agent - **攻防协同演化评测基准**: 含预留的未知攻击, 量化已知/未

知防御

工作计划 + 预期成果 0.7 - 计划: 下半年框架原型 → 年底闭环 + 实验 → 明年上半年评测 + 中期 → 撰写投稿 → 6 月答辩 - 成果: 学位论文; 开源系统 + **harness** + 评测基准; 必要时向 IETF/Linux 负责任披露

致谢 0.3 - 一句总结: 把攻击者视角反向用于防御, 让智能体以“防御演化”自主维护内核 eBPF 防御库 - “恳请各位老师批评指正, 谢谢!”

提示

- **加粗** = 必须说到的关键词; = 建议用时 (总约 13–15 分钟, 时间紧时优先压缩“相关工作”与“工作计划”)。
- 看图的页 (架构、闭环、四层) 边指边讲, 不要照读文字。
- 答辩提问预案见《演讲稿》文末 Q1–Q5。